



本科毕业论文（设计）

基于多智能体与检索增强生成的智能运动训练系统

Intelligent Sports Training System Based on Multi-Agent
and Retrieval-Augmented Generation

学 院： 软件学院

专 业： 软件工程

学生姓名： 刘冰彦

学 号： 2230126

指导教师： 李令昆

北京交通大学

2026 年 4 月

学士论文版权使用授权书

本学士论文作者完全了解北京交通大学有关保留、使用学士论文的规定。特授权北京交通大学可以将学士论文的全部或部分内容编入有关数据库进行检索，提供阅览服务，并采用影印、缩印或扫描等复制手段保存、汇编以供查阅和借阅。

（保密的学位论文在解密后适用本授权说明）

学位论文作者签名：

指导教师签名：

签字日期： 年 月 日

签字日期： 年 月 日

学士论文诚信声明

本人声明所呈交的毕业论文（设计），题目_____是本人在指导教师的指导下，独立进行研究工作所取得的成果。尽我所知，除了文中特别加以标注和致谢中所罗列的内容以外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京交通大学或其他教育机构的学位或证书而使用过的材料。

申请学位论文与资料若有不实之处，本人承担一切相关责任。

本人签名：_____ 日期：_____

中文摘要

摘要：[鼠标左键单击选择该段落，输入替换之。内容为小四号宋体。] 中文摘要应将论文的内容要点简短明了地表达出来，约 400 字左右，字体为宋体小四号。内容应包括工作目的、研究方法、成果和结论。要突出本论文的创新点，语言力求精炼。为了便于文献检索，应在本页下方另起一行注明论文的关键词（3-5 个），如有可能，尽量采用《汉语主题词表》等词表提供的规范词。图 X 幅，表 X 个，参考文献 X 篇。

随着全民健身战略推进，科学训练需求日益增长，但普通爱好者面临训练计划缺乏科学性、私教成本高昂等问题。近年来，大语言模型与智能体技术为智能化运动训练提供了新路径，但通用模型在体育场景中仍存在专业知识不足、缺乏权威依据、无长期用户记忆等局限。为解决这些问题，本文设计并实现了一个基于多智能体与检索增强生成（RAG）技术的智能运动训练系统。

系统核心创新点包括：（1）设计了三个专业虚拟教练智能体，包括训练规划教练、技术指导教练和运动康复教练，通过 LangGraph 状态图实现协同决策；（2）实现了多查询扩展（MQE）和假设文档嵌入（HyDE）相结合的高级检索策略，显著提升了知识检索的准确性和召回率；（3）构建了四层记忆管理系统，包括工作记忆、情景记忆、语义记忆和感知记忆，支持多轮对话和上下文理解。

系统采用前后端分离架构，后端使用 FastAPI、LangChain 和 LangGraph 等技术栈，前端采用 Vue3 框架。系统支持多模态文档处理，能够从 PDF 文件中提取图像并生成语义描述，实现统一的知识检索。通过系统测试，验证了系统的功能完整性和响应性能，平均响应时间约为 XX 秒，检索准确率达到 XX.X %。

本文的研究成果为运动训练指导提供了一种创新的智能化解决方案，有效提升了训练指导的个性化和专业化水平，具有重要的理论意义和实际应用价值。

关键词：大语言模型；检索增强生成；多智能体系统；智能运动训练；向量数据库

ABSTRACT

ABSTRACT:

"[鼠标左键单击选择该段落，输入替换之。内容为小四号 Times New Roman。]" 与中文摘要内容要相对应。

KEYWORDS: [请输入英文关键词，与中文关键词保持一致。以分号分隔。]

目 录

中文摘要.....	I
ABSTRACT.....	III
目 录.....	IV
1 引言.....	1
2 1 级标题（小四、黑体、左对齐、空 1 字符）.....	错误!未定义书签。
2.1 2 级标题（小四、宋体、首行缩进 1 字符）.....	错误!未定义书签。
2.1.1 3 级标题（小四、宋体、首行缩进 2 字符）.....	错误!未定义书签。
3 1 级标题.....	错误!未定义书签。
3.1 2 级标题.....	错误!未定义书签。
3.1.1 3 级标题.....	错误!未定义书签。
4 1 级标题.....	错误!未定义书签。
4.1 2 级标题.....	错误!未定义书签。
4.1.1 3 级标题.....	错误!未定义书签。
5 结论.....	33
参考文献.....	34
致 谢.....	错误!未定义书签。

目录说明：

- 1 级标题（小四、黑体、左对齐、空 1 字符）
- 2 级标题（小四、宋体、首行缩进 1 字符）
- 3 级标题（小四、宋体、首行缩进 2 字符）

1 引言

[鼠标左键单击选择该段落，输入替换之。内容为小四号宋体。] 引言（或绪论）简要说明研究工作的目的、范围、相关领域的前人工作和知识空白、理论基础和分析、研究设想、研究方法和实验设计、预期结果和意义等。应言简意赅，不要与摘要雷同，不要成为摘要的注释。一般教科书中有的知识，在引言中不必赘述。

1.1 研究背景

随着全民健身意识的不断提高和科学训练理念的普及，越来越多的人开始关注运动训练的科学性和有效性。传统的运动训练指导主要依赖于教练的个人经验和专业判断，虽然在一定程度上能够满足基本需求，但存在明显的局限性。首先，优质教练资源稀缺且分布不均，导致大部分训练者难以获得专业的指导；其次，教练的知识储备更新速度相对缓慢，难以及时掌握最新的运动科学研究成果；此外，传统的一对多教练模式难以实现真正意义上的个性化训练，无法针对每个人的体质、目标和特点提供定制化方案。

近年来，人工智能技术特别是大型语言模型的突破性进展，为运动训练指导领域带来了新的机遇。LLM 具有强大的知识理解和生成能力，能够处理复杂的自然语言查询，生成连贯且专业的建议。通过将 LLM 应用于运动训练领域，可以构建智能化的训练指导系统，为用户提供个性化、专业化和实时性的训练建议。

然而，通过对相关文献的系统梳理发现，现有同类产品与解决方案仍存在以下共性不足：首先，模型可能产生幻觉，即生成不准确或虚构的训练建议；其次，现有系统多为“无状态”设计，即每次交互独立处理用户请求，无法持续追踪用户的训练历史、身体状态变化及恢复情况；最后，运动训练本身是一个涉及训练多学科知识的复杂过程。然而，现有系统往往由单一知识模型驱动，难以整合多领域专业知识。现有研究多聚焦于训练管理而非多角色协同指导，尚未实现训练规划、技术指导、运动康复等角色的专业化分工与协作。

1.2 研究意义

1.2.1 理论意义

本文的研究具有重要的理论意义。首先，探索了多智能体系统在运动训练领域的应用模式，为智能体协作决策机制提供了新的研究视角。通过设计多个具有不同专业职责的虚拟教练，并利用 LangGraph 状态图实现协同工作流，丰富了多智能体系统在垂直领域应用的理论框架。

其次，本文结合了高级检索技术（包括多查询扩展 MQE 和假设文档嵌入 HyDE）与 RAG 架构，深入研究了如何提升检索增强系统的准确性和召回率。通过对比分析不同检索策略的性能表现，为相关领域的算法优化提供了一定的理论参考。

此外，本文构建了四层记忆管理系统，涵盖工作记忆、情景记忆、语义记忆和感知记忆，从认知科学角度模拟人类记忆机制。这一设计为 AI 系统如何有效管理和利用长期记忆提供了有价值的参考。

1.2.2 实际应用价值

本文的研究成果具有广泛的实际应用价值。对于普通健身爱好者而言，系统提供了一种便捷、专业的训练指导渠道，用户可以通过简单的自然语言交互获得个性化的训练计划、动作指导和康复建议，大大降低了获取专业训练知识的门槛。

对于体育院校和训练机构而言，系统可以作为辅助教学工具，帮助教练减轻部分重复性工作，提高教学效率和质量。系统内置的标准化训练知识库确保了教学内容的科学性和一致性，有利于规范化的训练指导体系建设。

对于运动康复领域，系统提供的损伤预防和恢复建议能够帮助训练者降低运动损伤风险，提高训练安全性，并持续追踪用户身体机能变化，辅助用户科学回归正常训练或维持健康状态。

1.3 国内外研究现状

1.3.1 智能运动训练系统研究现状

随着全民健身战略的推进，数智技术与运动健康服务的深度融合已成为学术界与产业界关注的热点^[1]。市场上涌现出各类运动训练 APP（如 Nike Training Club、Keep 等），学术界亦围绕运动训练智能化开展了多项研究^[2-5]。然而，通过对相关文献的系统梳理发现，现有同类产品与解决方案仍存在以下不足：

（1）训练建议缺乏科学依据与可解释性

现有运动指导系统普遍依赖通用规则库或简单算法生成训练建议，缺乏权威运动科学知识的支撑。研究表明，当前数智化运动健康服务面临“指标科学性欠缺”的现实

- 批注 [K11]: [1] 程宇飞. 数智技术精准嵌入社区运动健康服务的作用机理与推进路径[J]. 体育学刊, 2025, 32(3): 63-71.
- [2] Xiao H, Ren J. Inter-Individual Heterogeneity in Aerobic Training Adaptations: Systematic Review of the Evidence Base for Personalized Exercise Prescription[J]. Life, 2025, 15(12): 1932.
- [3] 彭国强, 周志博. 中国运动训练学自主知识体系的生成演进与构建路径[J]. 首都体育学院学报, 2025, 37(1): 1-9.
- [4] Wang W. Informatization of Physical Education Curriculum Education and Training Management in Colleges and Universities under the Maximum Information Entropy Model[J]. Applied Mathematics and Nonlinear Sciences, 2024, 9(1): 1-15.
- [5] Meng X, Zhu J, Zheng J. Design and Practice of Personalized Guidance System Based on Artificial Intelligence in Sports Training[C]//2025 9th International Symposium on Innovative Approaches in Smart Technologies (ISAS). Gaziantep, Turkiye. New York: IEEE, 2025: 1-6.

挑战，多数系统难以提供可验证的训练依据^[1]。通用大语言模型虽具备自然交互能力，但在运动训练场景中依赖模型记忆生成内容，缺乏专业知识库的支撑，难以保证建议的准确性与可解释性。

（2）缺乏对用户长期状态的记忆与个性化适配能力

现有系统多为“无状态”设计，即每次交互独立处理用户请求，无法持续追踪用户的训练历史、身体状态变化及恢复情况。从运动科学视角看，个体对训练的适应性存在复杂差异，忽略个体历史表现的训练方案难以实现真正意义上的个性化处方^[2]。

（3）多学科知识整合不足，缺乏协同指导机制

运动训练本身是一个涉及训练多学科知识的复杂过程。然而，现有系统往往由单一知识模型驱动，难以整合多领域专业知识。现有研究多聚焦于训练管理而非多角色协同指导，尚未实现训练规划、技术指导、运动康复等角色的专业化分工与协作。

1.3.2 大型语言模型与 RAG 技术研究现状

近年来，大型语言模型（Large Language Models, LLM）在自然语言处理领域取得了突破性进展，在问答、对话、推理等任务中表现出强大的能力。然而，LLM 在实际应用中仍面临知识时效性不足、幻觉问题严重等挑战。

为解决上述问题，检索增强生成（Retrieval-Augmented Generation, RAG）被提出并广泛应用。该方法通过将外部知识库与生成模型结合，使模型在生成回答时能够引用真实知识，从而显著提升回答的准确性与可信度。研究表明，RAG 模型在知识密集型任务中相比纯生成模型具有更高的准确性和可解释性^[6]。

在 RAG 技术的发展过程中，研究者提出了多种优化策略，包括：

- （1）多查询扩展（Multi-Query Expansion, MQE），提升检索召回率；
- （2）假设文档嵌入（HyDE）^[7]，通过生成假设文本改善检索效果；
- （3）多轮检索与重排序机制，提高知识匹配质量。

此外，随着应用需求的提升，Agentic-RAG（智能体增强 RAG）^[10]逐渐成为研究热点。该方法通过引入智能体机制，使模型能够动态选择检索策略、调用工具并执行复杂任务，从而提升系统的自主性和复杂任务处理能力。

1.3.3 多智能体系统研究现状

多智能体系统（Multi-Agent System, MAS）是人工智能领域的重要研究方向，其核心思想是通过多个智能体协同完成复杂任务。近年来，随着 LLM 的发展，基于 LLM 的多智能体系统成为研究热点。

批注 [K12]: [6] Lewis P, Perez E, Piktus A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[C]//Advances in Neural Information Processing Systems. 2020: 9459-9474.

批注 [K13]: [7] Gao L, Ma X, Lin J, et al. Precise Zero-Shot Dense Retrieval without Relevance Labels[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics. Toronto, Canada. Stroudsburg, PA: Association for Computational Linguistics, 2023: 1762-1777.

批注 [K14]: [10] Singh A, Ehtesham A, Kumar S, et al. Agentic Retrieval-Augmented Generation: A Survey on Agentic RAG[EB/OL]. arXiv:2501.09136, 2025.

在理论层面，研究者提出了多种经典的智能体架构范式，如“思考—行动—观察”闭环结构^[11]，或是让智能体先制定计划、再按照计划严格执行^[12]，以及集成记忆、规划、行动与工具调用能力的模块化框架。

在应用层面，多智能体系统已被应用于机器人协作、软件工程、医疗辅助等复杂场景。例如，基于 LLM 的多智能体系统可以通过任务分解、角色分配和协同推理完成复杂任务，在多机器人任务规划中已取得良好效果^[13]。此外，在医疗领域，多智能体系统通过模拟多学科专家协作，提高了决策质量与系统可靠性。

同时，研究也表明，多智能体系统结合 RAG 技术能够进一步提升性能，通过专业化智能体分工与协同，可以显著提高系统的准确性与可解释性^[14]。

1.4 本文主要研究内容

基于上述研究背景和技术发展现状，本文的主要研究内容包括：

（1）智能运动训练系统的需求分析和架构设计。分析系统的功能需求和非功能需求，设计包括多智能体协同、RAG 检索、记忆管理在内的整体架构。

（2）多智能体协同训练支持系统的设计与实现。设计训练规划教练、技术指导教练、体能评估教练、运动康复教练和安全督导教练等专业智能体，基于 LangGraph 构建协作状态图，实现意图识别、教练路由和综合响应生成。

（3）高级检索增强生成技术的实现。研究并实现多查询扩展（MQE）和假设文档嵌入（HyDE）两种高级检索策略，结合向量数据库构建高效的 RAG 系统，提升知识检索的准确性和召回率。

（4）多层次记忆管理系统的构建。设计并实现工作记忆、情景记忆、语义记忆和感知记忆四层记忆架构，支持多轮对话上下文管理和长期知识积累。

（5）前后端系统的开发。采用 FastAPI 构建后端 API 服务，使用 Vue3 开发前端用户界面，实现前后端分离的系统架构，提供 Web 化的交互方式。

批注 [K15]: [11] WANG L, XU W, LAN Y, et al. Plan-and-Solve Prompting: Improving Zero-Shot Chain-of-Thought Reasoning by Large Language Models[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics. Toronto, Canada. Stroudsburg, PA: Association for Computational Linguistics, 2023: 2609-2634.
[12] YAO S, ZHAO J, YU D, et al. ReAct: Synergizing Reasoning and Acting in Language Models[C]//The Eleventh International Conference on Learning Representations. Kigali, Rwanda. 2023.

批注 [K16]: [13] KANNAN S S, VENKATESH V L N, MIN B C. SMART-LLM: Smart Multi-Agent Robot Task Planning using Large Language Models[R/OL]. arXiv preprint arXiv:2309.10062, 2024[2026-04-04]. <https://doi.org/10.48550/arXiv.2309.10062>.
[14] ALTHAF A M, MOHAMMED M A, MILANOVA M, et al. Multi-Agent RAG Framework for Entity Resolution: Advancing Beyond Single-LLM Approaches with Specialized Agent Coordination[J/OL]. Computers, 2025, 14(12): 525[2026-04-04]. <https://doi.org/10.3390/computers14120525>.

2 相关技术综述

本章主要介绍本文涉及的相关技术，包括大语言模型（LLMs）、检索增强生成（RAG）技术和多智能体系统。

2.1 大语言模型

2.1.1 大语言模型发展历程

大语言模型的发展可以追溯到 2017 年 Google 提出的 Transformer 架构。Transformer 采用自注意力机制，显著提升了序列建模的能力，为后续的语言模型研究奠定了基础^[15]。此后，GPT 系列模型采用解码器架构，通过大规模预训练获得语言理解能力；BERT 系列模型则采用编码器架构，在自然语言理解任务上表现优异^[16]。

2020 年，OpenAI 发布了 GPT-3 模型，参数量达到 1750 亿，展现出强大的少样本学习能力。GPT-3 的出现标志着大规模预训练模型进入实用阶段。2022 年底，ChatGPT 的推出引发全球关注，其流畅的对话能力和广泛的知识储备令用户印象深刻。2023 年，GPT-4 发布，进一步提升了模型在复杂推理、代码生成等任务上的表现。2025 年，以 OpenAI o1 和 DeepSeek-R1 为代表的推理模型问世，通过强化学习攻克了复杂逻辑难题，Agentic RAG 成为解决幻觉的主流方案。

2.1.2 主流大语言模型对比

目前大语言模型（LLM）已进入“后大规模预训练”时代，竞争焦点从单纯的参数量转向了推理性能（Reasoning）、长文本处理（Long Context）以及智能体协同（Agentic Capability）。

表 2-1 主流大语言模型对比

模型名称	核心优势	推理能力	上下文窗口
GPT-5.4 (OpenAI)	综合能力、生态集成	极强 (o-series 领先)	400K - 1M
Claude 4.6 (Anthropic)	代码编程、自然语感	极强	200K - 500K

批注 [K17]: [15] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]//Proceedings of the 31st International Conference on Neural Information Processing Systems. 2017: 5998-6008. [16] DEVLIN J, CHANG M W, LEE K, et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Minneapolis, Minnesota. Stroudsburg, PA: Association for Computational Linguistics, 2019: 4171-4186.

Gemini 3.1 (Google)	超长上下文、视 频理解	强 (GPQA 表现优异)	10M+ (行业最 高)
DeepSeek-V3.2/R1	极高性价比、深 度推理	极强 (R1 逻辑闭环)	128K - 256K
Llama 4 (Meta)	开源社区支持、 私有化	强	128K - 512K

2.2 检索增强生成技术

2.2.1 RAG 技术原理

2.2.2 向量数据库

2.2.3 高级检索策略

2.3 多智能体系统

2.3.1 多智能体系统概述

2.3.2 LangGraph 框架

3 系统总体设计

3.1 系统需求分析

3.1.1 功能性需求分析

根据对智能运动训练系统的应用场景分析，系统需要满足以下功能需求：

第一，智能问答功能：用户可以通过自然语言输入关于运动训练的各种问题，系统返回专业、准确的答案。

第二，训练计划生成功能：系统能够根据用户的目标、当前水平、可用时间等条件，生成个性化的训练计划。计划应包括训练目标、周期安排、具体训练内容等。

第三，多智能体协同功能：系统能够根据用户问题的类型，自动选择合适的智能体组合进行回答，提供全方位的专业建议。

第四，知识库管理功能：支持管理员查看、更新知识库内容。

第五，记忆管理功能：系统能够记录用户的对话历史和关键信息，支持多轮对话的上下文理解。管理员可以查看记忆摘要、管理记忆。

3.1.2 非功能性需求分析

系统需要满足以下非功能性需求：

第一，性能需求：系统应保证良好的响应速度，平均响应时间应在 5 秒以内。对于复杂的多智能体查询，最长响应时间不超过 15 秒。

第二，可靠性需求：系统应保证稳定运行，连续运行时间达到 99.5%以上。API 接口应具备容错和重试机制。

第三，可扩展性需求：系统应支持知识库的扩展和智能体的添加。架构应采用模块化设计，便于后续功能扩展。

第四，易用性需求：界面设计简洁直观，用户无需复杂学习即可使用。

3.2 系统架构设计

3.2.1 总体架构

本文设计的智能运动训练系统采用前后端分离的架构，整体架构如图 3-1 所示。系统分为前端用户界面、后端 API 服务、多智能体协同系统、RAG 检索系统、记忆管理模块和向量数据库存储等组件。




图 3-1 系统整体架构设计

3.3 多智能体模块设计

3.3.1 教练智能体角色设计

系统设计了 3 个专业虚拟教练，每个教练负责特定的运动训练领域。各教练的角色定义如表 3-2 所示。

表 3-1 教练智能体角色定义

智能体名称	职责描述	激活关键词
训练规划教练	根据用户目标、能力和历史数据制定科学训练计划并动态优化	计划、规划、周期、目标、安排

技术指导教练	提供规范的动作指导和详细的姿势分析	动作、姿势、技术、要领、标准、纠正
运动康复教练	针对运动损伤风险或已出现的伤痛提供预防措施与恢复建议	恢复、康复、损伤、伤痛、预防、建议

每个虚拟教练都是一个独立的智能体，具有以下特性：

- （1）专业性：每个教练专注于特定领域，能够提供深入的专业建议。
- （2）独立性：每个教练可以独立处理相关领域的问题。
- （3）协作性：多个教练可以协同工作，后执行的教练可以获取前序教练的输出。
- （4）个性化：每个教练的提示词和参数可以根据具体需求进行配置。

3.3.2 智能体协作流程设计

系统设计了以下两种智能体模式：

- （1）单智能体模式：当用户问题涉及单一领域时，系统只激活对应的教练。
- （2）多智能体综合咨询模式：当用户问题涉及多个领域或用户是新用户时，系统激活多个教练协同工作。

图 3-2 展示了多智能体模块的详细架构：




图 3-2 多智能体模块详细架构

3.4 RAG 检索模块设计

3.4.1 文档处理流程

文档处理模块负责将原始文档转换为可检索的向量数据。处理流程如图 3-3 所示，包括文档解析、内容提取、文本分块、向量化和索引存储五个步骤。




图 3-3 文档处理流程图

3.4.2 高级检索策略

本系统的 RAG 检索模块采用多查询扩展（MQE）和假设文档嵌入（HyDE）相结合的高级策略。多查询扩展模块将用户问题转换为多个语义相关的查询变体，每个变体独立进行检索，最后合并结果。假设文档嵌入模块首先生成假设性答案，然后使用假设答案的向量进行检索，从而提升检索模块的召回率。检索结果融合模块将两种策略的结果进行合并和排序。

3.5 记忆模块设计

3.5.1 四类记忆模型

系统采用四类记忆模型，模拟人类记忆系统的结构，记忆模型如图 3-4 所示。




图 3-4 记忆模型结构

各类记忆的详细说明如表 3-2 所示。

表 3-2 四类记忆模型说明

记忆类型	存储内容	更新频率	容量限制	使用场景
工作记忆	当前对话上下文，最近 N 轮对话	每次交互更新	10 轮对话	多轮对话上下文理解
情景记忆	历史问答交互，包括问题、答案、检索文档	每次交互更新	无限制 (可清理)	历史查询追溯
语义记忆	概念知识和理解	偶尔更新 (通过归纳)	无限制 (可清理)	领域知识理解
感知记忆	文档特征、图像描述等多模态信息	文档、图像处 理时更新	无限制 (可清理)	多模态信息关联

3.5.2 记忆管理机制

3.6 数据库设计

4 系统实现

4.1 开发环境与技术栈

系统开发在以下环境中进行：

（1）操作系统：Windows 11，也可以在 Linux 和 macOS 系统上运行。

（2）编程语言：Python 3.12 用于后端开发，JavaScript/TypeScript 用于前端开发。

（3）开发工具：VS Code 作为主要开发 IDE，使用 Vite 作为前端构建工具。

（4）数据库：ChromaDB 作为向量数据库，SQLite 作为关系型数据库。

（5）API 服务：阿里云通义千问 API 作为大语言模型服务。

系统技术栈如表 4-1 所示。

表 4-1 系统技术栈

层次	技术选型	版本	说明
前端框架	Vue	3.4.0	渐进式 JavaScript 框架
构建工具	Vite	5.0.0	前端构建工具
状态管理	Pinia	2.1.7	Vue 状态管理库
路由管理	Vue Router	4.2.5	Vue 路由库
HTTP 客户端	Axios	1.6.0	HTTP 请求库
LLM 框架	LangChain	0.3.0	LLM 应用框架
状态图框架	LangGraph	0.2.0	状态图管理框架
向量数据库	ChromaDB	0.5.0	向量存储和检索
文档处理	MarkItDown	0.0.1a2	文档转换工具
图像处理	PyMuPDF	1.23.0	PDF 图像提取
LLM 服务	DashScope	1.19.0	阿里云大模型服务

4.2 后端服务实现

后端项目结构如下：




图 4-X 后端项目结构

4.2.1 FastAPI 框架搭建

后端采用 FastAPI 框架搭建 RESTful API 服务。FastAPI 是现代、快速的 Python Web 框架，具有异步支持、自动 API 文档生成、数据验证等特性。

API 模块组织如下：

- （1）主应用：负责全局配置、中间件、异常处理和路由注册。
- （2）API 路由：包括查询接口、知识库接口、记忆接口、多智能体接口等。
- （3）依赖注入：使用 FastAPI 的依赖注入功能管理各模块依赖。
- （4）中间件：配置 CORS 中间件、请求日志中间件、异常处理中间件等。

4.2.2 多智能体模块实现

1. 概述

多智能体模块是系统的核心组件，模拟真实运动训练团队的协作模式。通过多个专业教练智能体的协同工作，为用户提供全面、专业的训练建议。模块类图如下所示：



图 4-1：多智能体模块类图

该模块采用状态图（StateGraph）实现智能体间的协作流程控制。




图 4-2：StateGraph 类图

该模块的状态数据结构是 TrainingState:




图 4-3: TrainingState 类图

2. 教练智能体设计

教练智能体继承自下图的 CoachAgent 基类



图 4-4: CoachAgent 类图

(1) 训练规划教练




图 4-5: 训练规划教练类图

训练规划教练的核心功能是：

- A. 根据用户目标、能力和历史数据制定科学训练计划
- B. 输出结构完整的 Markdown 训练计划草案
- C. 支持按周、按训练日详细安排
- D. 动态调整计划内容

(2) 技术指导教练




图 4-6: 技术指导教练类图

技术指导教练的核心功能是：

- A. 提供规范的动作指导
- B. 分析标准姿势要领
- C. 指出最容易出错的地方
- D. 需要加入最终计划的技术提示

(3) 运动康复教练



图 4-7：运动康复教练类图

运动康复教练的核心功能是：

- A. 针对运动损伤风险提供预防措施
- B. 为已出现的伤痛提供恢复建议
- C. 输出高风险动作
- D. 提供可替代动作或调整方式

3. 状态图设计

系统采用 LangGraph 构建协作状态图，实现智能体间的协调。

节点定义如下：

表 4-X：多智能体模块状态图节点定义

节点	功能	描述
retrieve_knowledge	知识检索	从向量数据库检索相关知识
build_execution_plan	构建执行计划	分析请求，选择教练，构建执行批次
execute_agents	执行教练	按批次执行教练智能体
synthesize_response	综合响应	整合所有教练建议，生成最终回答
update_memory	更新记忆	将交互记录到记忆系统

系统通过 `analyze\_request` 方法提取路由信号，动态选择参与的教练，如下表所示：

表 4-X：多智能体模块信号提取规则

信号	触发关键词	涉及教练
planning	"计划", "规划", "安排", "周期", "目标"	训练规划教练
technique	"动作", "姿势", "技术", "要领", "标准", "纠正"	技术指导教练
recovery	"恢复", "康复", "损伤", "伤痛", "拉伤", "酸痛", "不适", "风险", "危险", "注意", "防护", "禁忌"	运动康复教练

4.2.3 RAG 检索模块实现

1. 概述

RAG（Retrieval-Augmented Generation）检索增强生成模块是系统的知识获取核心组件，负责从知识库中检索与用户问题相关的文档内容，为大模型提供准确的上下文信息。该模块集成了多种先进的检索技术，包括多查询扩展（MQE）和假设文档嵌入（HyDE），以显著提升检索质量和召回率。




图 4-8 RAG 检索模块类图

2. VectorStoreService 类

(1) 核心属性:

表 4-X: VectorStoreService 类核心属性说明

属性	类型	说明
vector_store	Chroma	Chroma 向量数据库实例

doc_processor	DocumentProcessor	智能文档处理器
persist_directory	Path	向量数据库持久化目录
collection_name	str	集合名称（默认：sports_training）

（2）核心方法：

表 4-X: VectorStoreService 类核心方法说明

方法名	返回类型	功能说明
get_retriever()	Retriever	获取向量存储的检索器
load_documents()	None	从数据文件夹加载知识库文档
process_pdf(path)	List[Document]	处理 PDF 文件
process_markdown(path)	List[Document]	处理 Markdown 文件
process_text(path)	List[Document]	处理纯文本文件

3. AdvancedRetriever 类

（1）核心属性：

表 4-X: AdvancedRetriever 类核心属性说明

属性	类型	默认值
base_retriever	Retriever	—
use_multi_query	bool	True
use_hyde	bool	True
num_queries	int	3
rerank_enabled	bool	False
mq_expander	MultiQueryExpansion	—
hyde_retriever	HyDERetriever	—

（2）核心方法：

表 4-X: AdvancedRetriever 类核心方法说明

方法名	返回类型	功能说明
retrieve(question)	List[Document]	执行高级检索，返回相关文档

4. MultiQueryExpansion 类

（1）核心方法：

表 4-X: MultiQueryExpansion 类核心方法说明

方法名	返回类型	功能说明
generate_queries(question)	List[str]	生成多个查询变体

5. HyDERetriever 类

（1）核心方法：

表 4-X: HyDERetriever 类核心方法说明

方法名	返回类型	功能说明
-----	------	------

generate_hypothetical_answer(question)	str	生成假设性答案
--	-----	---------

6. DocumentProcessor 类

（1）核心属性：

表 4-X: DocumentProcessor 类核心属性说明

属性	类型	默认值	说明
use_markitdown	bool	False	是否使用 MarkItDown 处理 PDF
extract_images	bool	True	是否提取 PDF 中的图像
image_description_enabled	bool	True	是否生成图像描述
md_splitter	MarkdownHeaderTextSplitter	—	Markdown 结构化分割器
text_splitter	RecursiveCharacterTextSplitter	—	递归字符分割器
image_output_dir	Path	data/extracted_images	图像输出目录

（2）核心方法：

表 4-X: DocumentProcessor 类核心方法说明

方法名	返回类型	功能说明
process_pdf(path)	List[Document]	处理 PDF 文件，转换为 Markdown 并分块
process_markdown(path)	List[Document]	处理 Markdown 文件，基于结构分割
process_text(path)	List[Document]	处理纯文本文件
_process_with_markitdown(path)	List[Document]	使用 MarkItDown 处理 PDF
_extract_and_describe_images()	List[Document]	提取图像并生成描述
get_image_descriptions_for_document(doc_id)	List[Dict]	获取文档的所有图像描述

7. 检索优化技术

（1）文档去重

基于文档内容的哈希值实现去重，确保检索结果不重复。

（2）重排序机制

重排序功能可选，基于关键词匹配对检索结果进行二次排序。

8. 知识库管理

（1）MD5 去重机制


先计算文档的 md5 哈希值，然后查询 md5 记录文件，检查该 md5 是否已经存在，如果不存在，则追加该 md5 值到 md5 记录文件

（2）支持的文档类型

表 4-X: 知识库支持的文档类型

文档类型	扩展名	处理方式
PDF	.pdf	MarkItDown（推荐）或 PyPDF
Markdown	.md	Markdown 分割器
纯文本	.txt	字符分割器

4.2.4 记忆管理模块实现



4.3 前端系统实现

4.3.1 Vue3 项目搭建

前端项目使用 Vite 创建，采用 Vue 3.4 版本。项目结构如下：




图 4-X 前端项目结构

- （1）src 目录：存放源代码，包括 api、assets、components、views、router 等子目录。
- （2）index.html：应用的 HTML 入口文件。
- （3）vite.config.js：Vite 配置文件，包含代理设置、构建选项等。
- （4）package.json：项目依赖和脚本配置。

4.3.2 页面实现

前端实现了以下主要页面组件：

1. AI 教练对话页面：系统的核心交互界面。页面左侧为会话历史列表，支持新建和删除对话。




图 4-X AI 教练对话页面

右侧为主聊天区域，AI 回复支持 Markdown 渲染，并可展开查看"思考过程"。当开启多智能体协作模式时，消息中会展示各专项教练的分析卡片。




图 4-X AI 教练对话示例

页面底部提供"生成计划""记录训练""记录饮食""记录体重"等快捷操作按钮, 用户还可上传图片 and 文档作为附件进行多模态提问。此外, 页面内嵌了训练问卷、计划预览、训练/饮食/体重记录等多个弹窗表单, 实现一站式交互。

2. 训练计划页面: 分为仪表盘和详情两种视图。仪表盘视图展示当前激活的训练计划卡片(含每周频率、时长、强度等标签)以及历史计划的翻页浏览。详情视图则以日历形式呈现训练安排, 用户点击日历中的训练日即可查看当天的具体训练内容。页面支持训练日选择、计划编辑和删除等操作, 计划内容以 Markdown 格式渲染, 并标注"AI 生成"标识。




图 4-X 训练计划页面

3. 知识库管理页面：用于给管理员管理系统的知识库文档。顶部展示文档总数、文本分块数和最后更新时间三项统计指标。主体区域以卡片网格展示已上传的文档列表，每个卡片显示文件类型图标、名称、大小、分块数量及加载状态。页面提供拖拽上传弹窗（支持 PDF、Markdown、TXT 格式）、关键词搜索过滤以及文档删除确认等功能，还有"加载知识库"按钮用于手动触发向量化处理。




图 4-X 知识库管理页面

4. 记忆管理页面：给管理员可视化展示系统的四层记忆结构。页面以四张卡片分别呈现：工作记忆（显示当前容量占比进度条，最大 5 轮）、情景记忆（问答历史记录数及状态）、语义记忆（概念知识数量及状态）和感知记忆（文档特征数量及状态）。页面底部列出近期活动日志，包括用户提问、系统响应、知识库加载等事件及其相对时间，管理员可点击刷新按钮获取最新的记忆摘要。



图 4-X 记忆管理页面

4.4 其他关键技术实现

4.4.1 多查询扩展实现

1. 实现流程

本系统的多查询扩展模块（MultiQueryExpansion）完整流程如图 4-X 所示。核心执行链路如下：

第一步：构建提示词。将用户原始问题注入 `multi_query_prompt` 模板，同时传入变体数量参数 `num_queries=3`，提示词内容如下：你是一个 AI 语言模型助手。你的任务是生成 `{num_queries}` 个不同版本的用户问题，以便从向量数据库中检索相关文档。通过从多个角度生成问题的不同表述，你的目标是帮助用户克服基于距离的相似性搜索的局限性。原始问题：`{question}`。请提供这些替代问题，每行一个问题，不要编号。




图 4-X 多查询扩展检索流程图

第二步：LLM 推理生成。调用 Qwen-Flash 大语言模型（temperature=0.7，top_p=0.9）对提示词进行推理，生成三个从不同语义角度表述同一问题的查询变体。

第三步：输出解析。通过 StrOutputParser 将模型输出按换行符 \n 分割，去除空行并进行 strip() 清洗，得到变体查询列表。

第四步：合并与截取。将原始问题插入列表首位，确保原始查询始终被检索，随后截取前 $\text{num_queries}+1=4$ 个查询作为最终的检索查询集合 $\{Q_0, Q_1, Q_2, Q_3\}$ ，其中 Q_0 为用户原始问题， $Q_1 \sim Q_3$ 为 LLM 生成的变体。

第五步：并行检索与合并。对 4 个查询分别调用基础检索器（`base_retriever.invoke(query)`），每路检索返回 $\text{top-k}=5$ 篇文档，4 路检索共可产生最多 $4 \times 5 = 20$ 篇候选文档。

第六步：去重与过滤。基于 `hash(page_content)` 对所有候选文档进行去重，并通过相似度阈值 `score_threshold=0.6` 过滤低相关性文档，最终经关键词匹配重排序（`rerank_enabled=true`）后输出最终候选文档集。

2. 关键参数配置

表 4-X 多查询扩展关键参数配置

参数名	配置值	说明
<code>use_multi_query</code>	<code>true</code>	MQE 功能开关
<code>num_queries</code>	3	LLM 生成变体查询数量
实际检索路数	4	含原始查询共 4 路并行
每路 <code>top-k</code>	5	每次检索返回文档数
最大候选文档数	20	合并后去重前上限
<code>score_threshold</code>	0.6	相似度阈值过滤
去重方式	<code>hash(page_content)</code>	基于文档内容哈希去重
重排序方式	关键词频次匹配	轻量级重排，可替换为 <code>Cross-Encoder</code>

3. 异常处理

当 LLM 生成过程发生异常时，模块自动降级为单查询模式，直接返回`[question]`列表，保证检索链路不中断。

4.4.2 HyDE 假设文档嵌入

1. 实现流程

本系统的 HyDE 模块（HyDERetriever）完整流程如图 4-X 所示，并与传统检索流程进行了对比。




图 4-X 传统检索与 HyDE 检索对比图

HyDE 流程详解：

第一步：构建假设文档生成提示词。将用户查询注入 `hyde_prompt` 模板，要求 LLM 生成一段专业、详细的运动训练领域答案，提示词内容如下：

请为以下问题编写一个假设性的、详细的答案。这个答案将用于检索相关文档。

问题：{question}。请生成一个专业、详细的假设答案（200-300 字），即使你不确定具体细节。

第二步：生成假设文档。调用 Qwen-Flash 模型推理，生成一段 200~300 字的专业假设性答案 `h`，其语言风格、术语密度与知识库中的专业运动训练文档高度相似。

第三步：假设文档向量化。调用 `text-embedding-v4` 嵌入模型对假设文档 `h` 进行向量化，得到向量 $v_h = \text{Embedding}(h)$ 。

第四步：向量检索。以 v_h 代替原始查询向量 $v_q = \text{Embedding}(q)$ 在 ChromaDB 中执行余弦相似度检索，返回语义最相近的 `top-k=5` 篇文档。

2. 与传统检索的对比分析

表 4-X 传统检索与 HyDE 检索对比

对比维度	传统检索	HyDE 检索
检索输入	短查询向量 v_q	假设文档向量 v_h
查询长度	通常 10~30 字	约 200~300 字
向量分布	与文档向量分布差异较大	与文档向量分布高度一致
计算开销	低（仅嵌入一次）	中（需一次 LLM 推理+嵌入）
召回精度	一般	显著提升
适用场景	专业领域精确问答	运动训练知识库问答

对于运动训练这一专业领域，知识库中的文档涉及大量专业术语（如"超量恢复"、"心率储备"、"DOMS"等），用户提问往往使用日常语言，与文档表述差距较大。HyDE 通过 LLM 桥接这一差距，在本系统中表现出了明显的检索质量提升效果。

3. 与 MQE 的组合使用

在本系统的高级检索器（AdvancedRetriever）中，HyDE 与 MQE 以串联+并行的方式协同工作：

HyDE 先行：首先对原始查询执行 HyDE 检索，得到基于语义对齐的 5 篇候选文档；

MQE 并行：随后对 4 个查询（含原始+3 个变体）分别执行向量检索，得到最多 20 篇候选文档；

合并去重：将两部分候选文档合并，基于内容哈希去重后最多可获得 25 篇原始候选文档；

重排序过滤：经关键词匹配重排序和相似度阈值过滤后，输出高质量最终候选文档集。

4. 异常处理

当 HyDE 的假设文档生成过程发生异常时，模块自动降级为使用原始查询字符串代替假设文档，保证整体检索链路的健壮性。结论【1 级标题，三号黑体字】

[鼠标左键单击选择该段落，输入替换之。内容为小四号宋或楷体字。] 论文的结论是最终的、总体的结论，不是正文中各段的小结的简单重复。结论应该准确、完整、明确、精练。如果不可能导出应有的结论，也可以没有结论而进行必要的讨论。可以在结论或讨论中提出建议、研究设想、仪器设备改进意见以及尚待解决的问题等。

参考文献

[内容为五号宋体。] 参考文献是文中引用的有具体文字来源的文献集合。按照 GB 7714《文后参考文献著录规则》的规定执行。

参考文献以文献在整个论文中出现的次序用[1]、[2]、[3].....形式统一排序、依次列出。

参考文献的表示格式为:

著作:

[序号] 作者.译者.书名.版本.出版地.出版社.出版时间.引用部分起止页

期刊:

[序号] 作者.译者.文章题目.期刊名.年份.卷号(期数).引用部分起止页

会议论文集:

[序号]作者.译者.文章名.文集名 .会址.开会年.出版地.出版者.出版时间.引用部分起止页

学位论文:

[序号]作者.题名[学位论文]（英文用[Dissertation]）.保存地点.保存单位.年份.引用部分起止页

专利:

[序号] 专利申请者.题名.国别.专利文献种类.专利号.发布日期.引用部分起止页

技术标准:

[序号] 起草责任者.标准代号.标准顺序号—发布年.标准名称.出版地.出版者.出版年份.引用部分起止页

致 谢

[鼠标左键单击选择该段落，输入替换之。内容为小四号宋或楷体字。] 放置在参考文献页后，对象包括：1) 国家科学基金，资助研究工作的奖学金基金，合同单位，资助或支持的企业、组织或个人。2) 协助完成研究工作和提供便利条件的组织或个人。3) 在研究工作中提出建议和提供帮助的人。4) 给予转载和引用权的资料、图片、文献、研究思想和设想的所有者。5) 其他应感谢的组织和个人。